

Tarea 3 - Reconocimiento de Patrones

Vicente Castro Solar
Pontificia Universidad Católica de Chile

–**Motivación:** En el caos que ha generado esta pandemia mundial, hemos aprendido que una de las etapas más cruciales en la lucha contra el coronavirus es la de diagnóstico. En esta tarea se explora como, desde el reconocimiento de patrones, se pueden desarrollar herramientas rápidas y eficiente que de ser usadas, pueden resultar claves para el combate contra esta epidemia.

1. Solución Propuesta

El problema de esta tarea era desarrollar un reconocedor automático que, a través de *patches* de radiografías de tórax, pudiera diagnosticar si una persona tiene neumonía, coronavirus o es si está sana. Para esto se trabajaron distintas estrategias de resolución, cada una de estas se encuentra explicada en los archivos `estrategia_{i}.ipynb` que acompañan a este informe. Cada estrategia presenta combinaciones de los siguientes items:

Feature Extraction:

Primero se extrajeron todas las características a utilizar¹ y se guardaron en archivos `.npy` (esto se hace en `prepare_data.py`). Luego, en cada notebook, se filtran los arrays según el nombre de la *feature* que se quiere utilizar.

Feature Transformation:

Se hicieron combinaciones de las siguientes técnicas `cleaning`, `normalization` (*mean* o *minmax*) y `PCA`.

Feature Selection:

En el archivo `modules/feature_selection` se encuentran implementaciones para `SFS` y `SBS`.

Classification:

La clasificación de *patches* individuales se llevó a cabo por distintos tipos de clasificadores y, a partir de estos resultados, se hizo un sistema de votaciones para clasificar al conjunto de *patches* que hacen una imagen.

2. Experimentos Realizados

A continuación se va a presentar cada estrategia y los resultados obtenidos de ellas:

En la **primera estrategia** se utilizaron las características geométricas y los descriptores de cada *patch*. Se realizó `cleaning`, `normalización(mean)` y `PCA(n=15)`. Para seleccionar características, se usó `SFS(n=7, method=sp100)`. La clasificación se hizo con Naive Bayes el cual logró una `accuracy` de 0.716 para la clasificación individual y un 0.754 para la grupal.

Para la **segunda estrategia** se usaron las *features* relacionadas a la intensidad. En el procesamiento se hizo `cleaning` seguido de una `normalización(minmax)` y para seleccionar características se usó `SFS(n=40)`. La clasificación se hizo con

¹Se catalogaron las *features* por **geometría**, **intensidad** y **descriptores** según como se describen en el libro *Computer Vision for X-Ray* que está en el *syllabus* del curso.

`KNN(K=11)`, del cual se obtuvo `acc=0.894` para *patches* individuales y 0.921 para la clasificación grupal.

En la **tercera estrategia** se quería acotar las *features* más significativas, por lo que se buscaron características geométricas y de intensidad. En la transformación de características se realizó una `Normalización(mean)` seguida por `PCA(n=15)`, no se realizó selección de características. En la clasificación se empleó una `SVM(rbf)` que obtuvo de `accuracy` 0.945 en el primer clasificador y 0.976 en el segundo.

La **cuarta estrategia** trató de integrar a las características de la estrategia 3 una característica significativa proveniente de los descriptores. Se hizo `cleaning` de los datos, una `normalización(mean)` y selección de características con `SBS(n=37)`. Para la clasificación se usó una Red Neuronal con dos capas ocultas que obtuvo como resultados `accuracy=0.959` en el primer clasificador y 0.976 en el segundo.

En la **quinta estrategia** se trabajó con las *features* que ya habían mostrado gran desempeño en experimentos anteriores. Además, se volvió a hacer la combinación `cleaning` con `normalization`, para la selección de características se usó `SFS(n=63)`. Como clasificador se utilizó el `output` de tres clasificadores (`SVM` y dos `NN`), con el cual se obtuvo una `accuracy` de 0.966 para el clasificador individual y 0.992 para el grupal.

	Clasificador I	Clasificador II
Estrategia 1	0,716	0,754
Estrategia 2	0,894	0,921
Estrategia 3	0,945	0,976
Estrategia 4	0,959	0,976
Estrategia 5	0,966	0,992

Figure 1: accuracy




Figure 2: Matriz I

Figure 3: Matriz II

Como se puede observar en las imágenes de arriba, la estrategia 5 fue la que logró obtener el mejor desempeño. Esto no solo se debe a la complejidad del clasificador que se empleó, si no que también a las *features* que se utilizaron.

3. Conclusiones

En esta tarea se desarrolló en su totalidad un reconocedor automático, por lo cual se obtuvo una apreciación más real de los procesos y la experimentación necesaria en proyectos de este tipo. En este sentido, se aprendió que la naturaleza de las imágenes, puede tener gran implicancia en las *features* con las que se debe trabajar, para el caso específico de rayos-X, se obtuvieron resultados muchos más significativos al utilizar características asociadas a la intensidad de grises de la imagen. También se tuvo la oportunidad de comparar el desempeño de diversos clasificadores, entre los cuales se pudo notar una clara diferencia entre la familia de clasificadores más complejos (`SVM`, `NN`) y otros más simples como `Bayes`, `KNN`.